伯乐 Scholar Agent — 搜索逻辑概览（PPT 版）

🎯 系统定位

一句话：输入 DOI → 自动找到第一作者和通讯作者的邮箱

📐 系统架构（5 阶段流水线）

```
flowchart LR
    A["📄 用户输入
文本 / PDF / XML"] --> B["🔍 DOI 提取"]
    B --> C["📡 论文元数据
获取"]
    C --> D["👤 作者识别
一作 + 通讯"]
    D --> E["📧 邮箱搜索
7 层信任链"]
    E --> F["📊 结果输出
实时推送 + 导出"]
```

📡 元数据获取：三通道瀑布策略

```
flowchart TD
    DOI["DOI"] --> E["🥇 EuropePMC
生物医学最强源
含通讯邮箱"]
    E -->|未收录| S["🥈 Semantic Scholar
结构化最好
含主页/ORCID"]
    S -->|未收录| C["🥉 Crossref
覆盖面最广
兜底"]

    style E fill:#22c55e,color:#fff
    style S fill:#3b82f6,color:#fff
    style C fill:#f59e0b,color:#fff
```

> 任一通道命中后，自动用 Crossref 补全缺失的机构/ORCID 信息

🔗 核心：7 层信任链邮箱搜索

层级	数据源	基础分	关键特点

层级	数据源	基础分	关键特点
L1	ORCID API 直查	**90**	最高可信源，公开邮箱直取
L2	Crossref 邮箱字段	**85**	出版商元数据中直接提供
L3	论文页面抓取	**80**	cloudscraper 绕反爬 + HTML 解析
L4	个人主页抓取	**75**	S2/ORCID 提供的 homepage
L5	同机构推断	**70**	🎯 一作专用：利用通讯作者的 lab 页
L6	LLM 联网搜索	**60**	通义千问联网模式搜索
L7	评分验证	—	所有结果必须过分数线

```
flowchart TD
    L1["L1 ORCID
90分"] --> L2["L2 Crossref
85分"]
    L2 --> L3["L3 论文页面
80分"]
    L3 --> L4["L4 主页
75分"]
    L4 --> L5["L5 同机构推断
70分 (一作专用)"]
    L5 --> L6["L6 LLM搜索
60分"]
    L6 --> FB["兜底：候选池最高分"]

    L1 -.->|"≥50分 命中"| OK["✅ 返回"]
    L2 -.->|"≥50分 命中"| OK
    L3 -.->|"≥50分 命中"| OK
    L4 -.->|"≥50分 命中"| OK
    L5 -.->|"≥50分 命中"| OK
    L6 -.->|"≥50分 命中"| OK

    style OK fill:#22c55e,color:#fff
```

> **设计哲学**：越靠上的层越可信，命中即停，避免低质量源污染结果

✅ 评分验证机制

```
最终得分 = 基础分(60~90) + 加分项 - 扣分项
```

评分项	分值
域名匹配机构	+10

评分项	分值
名字匹配邮箱	+10
多源交叉印证	+15
MX 验证通过	+5
MX 验证失败	-20
名字完全无关	-30

置信度	分数范围
🟢 高	≥ 70
🟡 中	50-69
🔴 低	< 50

🌟 设计亮点

```
### 💡 先通讯后一作
先搜通讯作者 → 结果传入一作搜索
一作可利用通讯的 Lab 页和机构域名推断自己的邮箱
<!-- slide -->
### 💡 LLM 只当导航器
LLM 不直接返回邮箱（会编造）
而是联网搜索 → 从回复中正则提取 → 再做独立验证
<!-- slide -->
### 💡 跨论文机构缓存
找到邮箱后缓存 `机构→域名` 映射
同批次后续论文的搜索自动加速
<!-- slide -->
### 💡 MX 记录验证
不仅看邮箱格式合法
还验证域名是否真实存在 MX 接收记录
```

📁 核心模块一览

模块	职责	代码量
`document_parser.py`	多格式 DOI 提取	~114 行
`doi_resolver.py`	三通道元数据获取	~405 行
`author_extractor.py`	一作/通讯识别	~143 行
`orcid_resolver.py`	ORCID 公开 API 查询	~164 行
`email_finder.py`	**7 层信任链搜索**	~903 行

模块	职责	代码量
`main.py`	FastAPI 流水线调度	~247 行